

Aufgabe 1: Schmucknachrichten

Teilnahme-ID: 76626

Bearbeiter/-in dieser Aufgabe:
Quirin Klemm

1. April 2025

Inhaltsverzeichnis

1	Lösungsidee	2
1.1	Perlen besitzen gleichen Durchmesser	2
1.2	Perlen mit unterschiedlichen Durchmesser	4
2	Umsetzung	5
3	Beispiele	6
4	Quellcode	6

1 Lösungsidee

Eine Nachricht besteht aus mehreren unterschiedlichen Buchstaben. Für jeden Buchstaben ist ein Codewort zu finden, wobei insgesamt ein präfixfreier Code entstehen muss. Dabei soll die Gesamtlänge der codierten Nachricht möglichst gering sein. Daher wird ein präfixfreier Code gesucht, bei dem häufig vorkommende Buchstaben kurze Codewörter erhalten, während seltenere Buchstaben längere Codewörter zugewiesen bekommen. Im Allgemeinen gilt, solange alle Perlen im Durchmesser gleich sind:

$$c_i = p_i \cdot n_i \quad (1)$$

$$l = \sum_i c_i \quad (2)$$

wobei:

- c_i die Kosten des Buchstaben i ist,
- p_i die Häufigkeit des Buchstaben i in der Nachricht darstellt,
- n_i die Länge des Codewortes für den Buchstaben i ist,
- l die Länge der codierten Nachricht ist.

Wenn sich die Durchmesser der Perlen unterscheiden, stimmt diese Gleichung nicht mehr und muss anders berechnet werden.

Um präfixfreien Code zu erzeugen, wird am besten ein Baum benutzt. Da man durch diesen sicher gehen kann, dass keine Codewort der Präfix eines anderen Codewort ist. Dabei ist jedes Blatt des Baums ein Codewort und jede Kante zu dem Blatt eine Code vom Codewort. Der Baum hat mindestens so viele Blätter wie es verschiedene Buchstaben gibt. Jeder interne Knoten hat dabei maximal so viele Kinder, wie es verschiedene Perlen gibt. Die Ebene des Blattes entspricht die Länge des Codewortes.




Abbildung 1: simple tree

1.1 Perlen besitzen gleichen Durchmesser

Um möglichst kleinen präfixfreien Code zu erstellen, muss der Buchstaben der am öftesten vorkommt ganz oben eingeordnet werden und die nächsten Buchstaben dann in absteigender Reihenfolge. In Abbildung 1 hätte c die höchste Häufigkeit und dann kommt a und b. Was von a und b die höhere Häufigkeit hat ist egal, da sie bei auf der untersten Ebene sind.

Daher ergibt sich $p_1 \geq p_2 \geq p_3 \dots \geq p_i$ und $n_1 \leq n_2 \leq n_3 \dots \leq n_i$

Zu finden ist also ein Baum, der basieren auf den Häufigkeiten der Buchstaben, seine Blätter so auf seine

Ebene so verteilt, dass die Gleichung (2) möglichst gering ist. Jeder interne Knoten muss dabei mindestens zwei Kinder haben, da ein interner Knoten mit nur einem Kind die Äste des Baums verlängern ohne irgendwelche anderen Vorteile dem Baum zu bringen.

Zu Beginn des Algorithmus wird ein perfekt ausbalancierter Baum erstellt, der so viele Blätter wie Buchstaben enthält (Abbildung 2). Jedes Blatt wird von links nach rechts in aufsteigender Reihenfolge mit einem Buchstaben belegt, und die Gesamtkosten des Baums werden gemäß der Formel (1) berechnet. Dabei ergeben sich deutlich höhere Kosten für die rechten Blätter des Baums im Vergleich zu den linken, da alle Blätter auf derselben Ebene sind, jedoch die Häufigkeit der Buchstaben auf der rechten Seite größer ist. Um das auszugleichen, wird das Blatt mit den höchsten Kosten eine Ebene nach oben verschoben. Dies geschieht indem der Elternknoten des Blattes selber zum Blatt wird und alle Kinder verliert. Dadurch hat der Baum insgesamt zu wenig Blätter, weshalb er erweitert werden muss. Dies geschieht, indem ab der Ebene des entfernten Blattes die Knoten von links nach rechts aufgefüllt werden, bis wieder genügend Blätter vorhanden sind. (Abbildung 3)

Das nach oben Verschieben und unten Neueinfügen der Blätter wird immer wieder wiederholt. (Abbildung 4) Der gesamte Algorithmus ist ein Optimierungsalgorithmus und versucht den Baum beim jeden Durchlauf ein wenig zu verbessern. Das geschieht solange bis die gesamte Kosten des Baums steigen, anstatt zu sinken.-




Abbildung 2: Balancierter Baum




Abbildung 3: Transformation 1




Abbildung 4: Transformation 2

1.2 Perlen mit unterschiedlichen Durchmesser

Das Problem bei unterschiedlichen Durchmesser besteht darin, dass Blätter auf derselben Ebene unterschiedliche Kosten haben können. Daher stimmt die Gleichung (1) nicht mehr, und muss statt dessen berechnet

$$c_i = p_i \cdot (cp_1 + cp_2 + \dots cp_n) \quad (3)$$

wobei:

- cp_n die Kosten/Durchmesser der Perle n ist.

Stellt man nun Bäume nicht nach ihrer Ebene, sondern nach ihren Kosten dar, erhält man einen *lopsided tree*.




Abbildung 5: lopsided tree: Perlendurchmesser: (1; 1; 2)

Auch hier gilt: Jeder interne Knoten muss mindestens zwei Kinder haben. Bei dieser Art von Bäumen hat jedoch nicht der rechteste Knoten die geringsten Kosten, sondern der oberste. Die Kosten eines Knoten sind:

$$K = K_E + K_S \quad (4)$$

wobei:

- K_E die Kosten seines Eltern Knoten sind
- K_S seine eigenen, neuen Kosten sind

Der Algorithmus bleibt unverändert: Zunächst wird ein Baum erstellt, in dem alle Blätter ungefähr die gleichen Kosten haben. Anschließend wird der Buchstabe mit den höchsten Kosten nach oben verschoben, während der Baum unten erweitert wird. Nach jedem Schritt werden die gesamte Kosten des Baums berechnet (Gleichung 2) und mit den letzten verglichen.

Wenn die Durchmesser alle gleich groß sind, gilt:

$$p_i \cdot (cp_1 + cp_2 + \dots cp_n) = p_i \cdot n_i \quad (5)$$

daher kann der zweite Algorithmus sowohl für gleiche als auch unterschiedliche Durchmesser benutzt werden.

2 Umsetzung

Die Lösung wurde in Python3 geschrieben. Die Eingabetexte werden eingelesen. Die Durchmesser der Perlen werden in einer Liste gespeichert und der Text in einem string. Aus dem Text werden anschließend zwei Listen erstellt: Die erste enthält die Häufigkeit der Buchstaben in absteigender Reihenfolge, die zweite listet die Buchstaben entsprechend dieser Sortierung auf.




Abbildung 6: TreeNode Klasse

3 Beispiele

Genügend Beispiele einbinden! Die Beispiele von der BwInf-Webseite sollten hier diskutiert werden, aber auch eigene Beispiele sind sehr gut – besonders wenn sie Spezialfälle abdecken. Aber bitte nicht 30 Seiten Programmausgabe hier einfügen!

4 Quellcode

Unwichtige Teile des Programms sollen hier nicht abgedruckt werden. Dieser Teil sollte nicht mehr als 2–3 Seiten umfassen, maximal 10.